

Восстановление функциональных групп головного мозга с помощью графовых диффузных моделей

А. И. Астахов, С. К. Панченко, В. В. Стрижов

astakhov.am@phystech.edu; panchenko.sk@phystech.edu; strijov@phystech.edu

В данной работе рассматривается задача классификации многомерного временного ряда, представляющего собой электроэнцефалограмму головного мозга человека. Стандартные подходы, использующие двухмерные свертки, не могут учесть пространственную структуру сигнала, поскольку датчики, считывающие показатели, находятся на сферической поверхности. В качестве решения предлагается использовать графовое представление функциональных групп, а для моделирования использовать нейронную диффузию.

Головной мозг, ЭЭГ, Графовые нейронные сети, диффузионные модели

1 Введение

Человеческий мозг — сложная система, функциональность которой определяется взаимодействием различных областей. Понимание этих связей важно для нейронаук, диагностики заболеваний и интерфейсов "мозг-компьютер". Современные методы, такие как электроэнцефалография (ЭЭГ), позволяют регистрировать многомерные временные ряды, но их анализ осложняется нерегулярной пространственной структурой и сложными функциональными связями.

Традиционные сверточные нейронные сети (CNN) неэффективны для таких данных, так как рассчитаны на регулярные сетки. Это стимулирует применение графовых нейронных сетей (GNN), которые могут моделировать функциональную связность мозга в виде графа. Узлы графа соответствуют областям мозга, а ребра — силе связей между ними. Однако многие GNN-методы игнорируют временную динамику активности мозга.

В данном исследовании предлагается использование Диффузионной сверточной рекуррентной нейронной сети (DCRNN), которая сочетает графовое моделирование пространственных зависимостей с рекуррентными нейронными сетями (RNN) для анализа временных данных. DCRNN позволяет моделировать как пространственную диффузию сигналов на графе, так и их динамику во времени. Этот подход решает проблемы нерегулярного расположения электродов и неевклидовой природы поверхности мозга.

Экспериментальная проверка проводится на открытых наборах данных. Основные этапы включают предобработку данных, построение графа, обучение модели и оценку её эффективности по метрикам, таким как точность классификации и интерпретируемость функциональных связей. Ожидается, что использование DCRNN позволит выявить сложные пространственно-временные паттерны активности мозга и углубить понимание функциональной связности.

2 Общее описание проблемы

Дана выборка $D = (\mathbf{X}, \mathbf{Z}, \mathbf{y})$, где \mathbf{X} — набор сигналов, \mathbf{Z} — координаты электродов, \mathbf{y} — целевая переменная. Цель — построить модель для декодирования активности мозга на основе иффузионной сверточной рекуррентной нейронной сети (DCRNN).

2.1 Постановка задачи

1. Множество данных:

$$\mathbf{X} = [\mathbf{X}_m]_{m=1}^M, \quad \mathbf{X}_m = [\mathbf{x}_t]_{t \in T}, \quad \mathbf{x}_t \in \mathbb{R}^E.$$

2. Графовая структура:

$$\mathcal{G}(m, t) = (\mathcal{V}(m, t), \mathcal{E}(m, t), \mathbf{A}_{\mathbf{X}, \mathbf{Z}}(m, t)),$$

где $\mathbf{A}_{\mathbf{X}, \mathbf{Z}}(m, t)$ — матрица смежности, определяющая веса ребер.

3. Модель DCRNN:

$$h_\theta : (\mathbf{X}, \mathbf{A}_{\mathbf{X}, \mathbf{Z}}) \rightarrow \mathbf{y}, \quad \theta \in \Theta,$$

где h_θ — диффузионная сверточная рекуррентная нейронная сеть, учитывающая пространственные и временные зависимости.

4. Функция ошибки:

$$\mathcal{L} = -\frac{1}{M} \sum_{m=1}^M \left[\sum_{c=1}^C \mathbb{I}(y_m = c) \log(p_m^c) \right],$$

где $p_m^c = h_\theta(\mathbf{X}_m, \mathbf{A}_{\mathbf{X}, \mathbf{Z}}(m))$ — вероятность класса c .

5. Оптимизационная постановка:

$$\theta^* = \arg \min_{\theta} \mathcal{L}.$$

2.2 Основные термины и определения

- **Модель:** h_θ — диффузионная сверточная рекуррентная нейронная сеть (DCRNN).
- **Решение:** θ^* — оптимальные параметры модели.
- **Алгоритм:** Процедура минимизации функции ошибки с использованием градиентного спуска.

3 Теоретическая часть

В данном разделе представлено решение задачи классификации многомерных временных рядов ЭЭГ с использованием графовых диффузионных моделей. Предлагаемый метод сочетает пространственное моделирование функциональных связей мозга с анализом временной динамики сигналов.

3.1 Предлагаемое решение

Решение задачи включает следующие этапы:

1. Построение графа функциональных связей между электродами
2. Применение диффузионных сверток для пространственного моделирования
3. Использование рекуррентных слоев для анализа временных зависимостей
4. Обучение модели с учителем для классификации паттернов ЭЭГ

3.2 Математическая модель

Графовая структура мозга представляется как $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{A})$, где:

- \mathcal{V} — множество вершин (электродов), $|\mathcal{V}| = E$
- \mathcal{E} — множество ребер (функциональных связей)
- $\mathbf{A} \in \mathbb{R}^{E \times E}$ — взвешенная матрица смежности

Матрица смежности строится на основе корреляции сигналов между электродами:

$$A_{ij} = \rho(x_i, x_j), \quad (1)$$

где $\rho(x_i, x_j)$ — коэффициент корреляции Пирсона между сигналами электродов i и j .

Для улучшения устойчивости модели можно применить пороговую обработку:

$$A_{ij} = \begin{cases} \rho(x_i, x_j), & \text{если } \rho(x_i, x_j) > \tau \\ 0, & \text{иначе} \end{cases} \quad (2)$$

где τ — пороговое значение корреляции.

3.3 Диффузионная свертка

Для пространственного моделирования используется диффузионная свертка:

$$\mathbf{H}^{(l+1)} = \sum_{k=0}^K \mathbf{P}^k \mathbf{H}^{(l)} \mathbf{W}_k,$$

где:

- $\mathbf{P} = \mathbf{D}^{-1} \mathbf{A}$ — нормированная матрица смежности
- $\mathbf{H}^{(l)}$ — скрытые представления на слое l
- \mathbf{W}_k — обучаемые параметры
- K — количество шагов диффузии

3.4 Временное моделирование

Для анализа временных зависимостей применяется GRU-слой:

$$\mathbf{z}_t = \sigma(\mathbf{W}_z[\mathbf{h}_{t-1}, \mathbf{x}_t]),$$

$$\mathbf{r}_t = \sigma(\mathbf{W}_r[\mathbf{h}_{t-1}, \mathbf{x}_t]),$$

$$\tilde{\mathbf{h}}_t = \tanh(\mathbf{W}[\mathbf{r}_t \odot \mathbf{h}_{t-1}, \mathbf{x}_t]),$$

$$\mathbf{h}_t = (1 - \mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t,$$

где $\mathbf{z}_t, \mathbf{r}_t$ — gates, \mathbf{h}_t — скрытое состояние.

3.5 Алгоритм обучения

Алгоритм 1 Обучение DCRNN модели

Вход: Множество данных $D = (\mathbf{X}, \mathbf{Z}, \mathbf{y})$, параметры модели

Выход: Обученная модель h_θ

- 1: Инициализировать параметры θ случайным образом
 - 2: Построить матрицы смежности $\mathbf{A}_{\mathbf{X}, \mathbf{Z}}$ для всех примеров
 - 3: **для** эпоха = 1 до MaxEpochs
 - 4: **для** пакет (\mathbf{X}_m, y_m) в D
 - 5: Вычислить предсказание: $\hat{y}_m = h_\theta(\mathbf{X}_m, \mathbf{A}_{\mathbf{X}, \mathbf{Z}}(m))$
 - 6: Вычислить потерю: $\mathcal{L} = -\log p_m^{y_m}$
 - 7: Обновить параметры: $\theta \leftarrow \theta - \alpha \nabla_\theta \mathcal{L}$
 - 8: **return** θ^*
-

3.6 Свойства решения

Предлагаемое решение обладает следующими свойствами:

- Учитывает неевклидову природу расположения электродов
- Моделирует как пространственные, так и временные зависимости
- Позволяет интерпретировать функциональные связи через матрицу смежности
- Устойчиво к шумам благодаря диффузионному процессу

Литература